기여도와 라운드별 변화를 보고 기관의 데이터 특징을 추론하는 데 단서가 될까?

- 연합학습에서 각 기관의 기여도를 평가한다면 해당 정보를 보고 기관이 가진 데이터의 특징도 짐작할 수 있지 않을까?
- Ex) 어떤 병원이 참여한 뒤 특정 질병의 예측 성능이 좋아졌다면 “이 병원에는 그 질병과 관련된 데이터가 많을까?” 라고 추측할 수 있을 것 같다.

➔기관별 기여도만으로 이런 추론이 가능할지

➔공격자가 데이터 특징을 추론할만한 정보(기여도, 변화)를 볼 수 있는 가능성이 있는지

높은 기여도를 유지하면서 예측 결과를 몰래 왜곡할 수 있을까?

- 악의적인 클라이언트가 일반적인 데이터에서는 좋은 성능을 보이면서, 특정 상황에서만 잘못된 예측을 하도록 파라미터를 조작할 수 있다면 기여도 평가에서는 문제가 드러나지 않고, 글로벌 모델에도 높은 비율로 반영될 수 있을 것 같다.
- Ex) 대부분의 숫자는 정확히 맞히지만 특정 표시가 있는 숫자 1만 7로 예측하도록 조작

➔이런 조작이 기여도 평가를 통과하고 높은 집계 비율을 받을 수 있을지

➔전체 정확도 외에 어떤 항목을 확인해야 이런 왜곡을 발견 가능한지

관련 연구를 찾아보았습니다.

- *Exploiting Unintended Feature Leakage in Collaborative Learning* — Melis 외, 2019
- 공유되는 모델 업데이트에서 다른 참여자의 비공개 데이터 특징을 추론할 수 있음을 보여줌

➔모델 업데이트가 아니라 기관별 기여도와 기여도의 변화만으로 추론이 가능할까?

- *How To Backdoor Federated Learning* — Bagdasaryan 외, 2020
- 악의적인 참여자가 모델 업데이트를 조작해 특정 입력에서 오답을 내는 백도어를 넣을 수 있음을 보여줌.

➔이런 조작이 기여도 평가에서도 드러나지 않고 높은 집계 비율을 받을 수 있을까?

논문의 그래프와 결론에 대한 이해(추가내용)

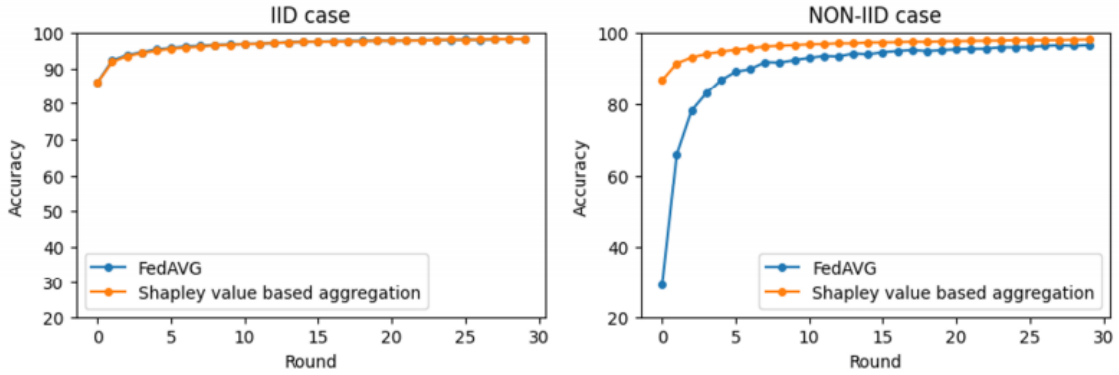


그림 4. IID 상황과 NON-IID 상황의 집계 결과 Accuracy 비교
Fig. 4. Accuracy comparison of aggregate results between IID and NON-IID situations

- IID: 두 방식의 정확도가 비슷하다.
- NON-IID: 30round 까지 논문이 제시한 방식의 정확도가 높다.

➔NON-IID case에선 후반에 두방식의 정확도 차이가 줄어들어도 초반 정확도에는 차이가 있다는 것을 알 수 있다.

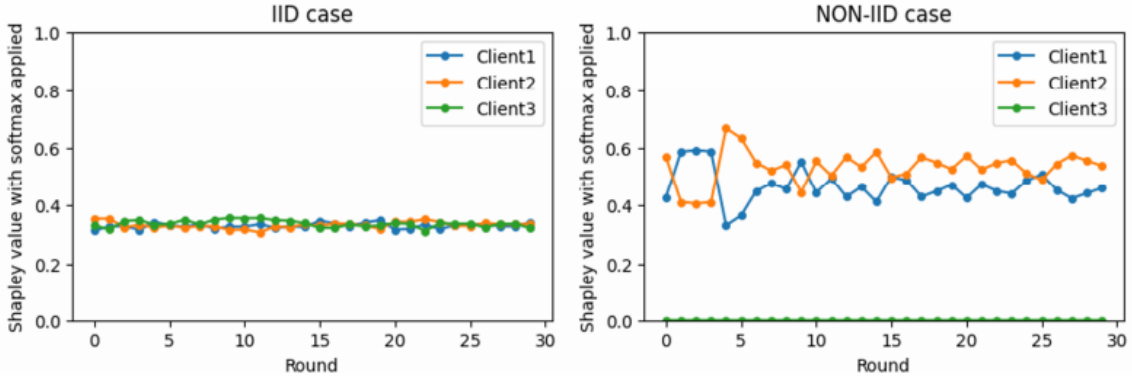


그림 5. round별 IID 상황과 NON-IID 상황의 s값 비교
Fig. 5. Comparison of s values between IID situation and NON-IID situation by round

- IID: 모든 client가 비슷한 기여도를 보여준다.
- NON-IID: label이 7,8,9만 존재하여 데이터 분포가 고르지 않은 client3의 기여도만 확실히 떨어지는 것을 확인할 수 있다.

➔데이터 분포가 고르지 않은 client3를 shapley value로 구분하여 softmax로 가중치를 부여하니, client3의 기여도는 0과 가까워 Global Model에 영향을 거의 주지 않는다.

논문의 그래프와 결론에 대한 이해(추가내용)

기존 FedAVG는 데이터의 개수만으로 가중치를 결정하여 데이터 분포까지 기여도에 적용할 수 없었는데

논문 제시 방식은 Global Model에 직접 기여하는 정도를 측정하여 가중치를 결정하기 때문에 FedAVG의 기존 성능은 유지하면서 단점을 보완한 알고리즘이라는 것을 확인할 수 있었다.

논문 제시방식의 문제점은 shapley value가 집합을 기반으로 기여도를 측정하기 때문에 클라이언트가 증가할 시 계산량이 지수적으로 늘어난다는 것이다.